Avaliação de um Modelo Simulado

Germano Bruscato, Laura Klippel, Luthero Vargas, Nicolas Warmeling

A realidade a ser simulada:

Modelamos o atendimento de incidentes de TI de uma empresa, a partir de um log real exportado do ServiceNow (Incident Management Process Enriched Event Log, UCI Machine Learning Repository). Quando um usuário abre um chamado, a maioria (52%) cai no primeiro nível.

O primeiro nível resolve a maior parte dos chamados, mas parte deles é encaminhada a grupos especialistas, e os especialistas muitas vezes devolvem o chamado ao primeiro nível ou o repassam a outro grupo. Esse vai e volta é o que torna o sistema uma rede de filas com retorno.

Limpeza de dados

1. **Filtragem do período:**
   - Filtrados para Março a Maio de 2016

2. Identificação de feriados:

- Feriados foram identificados por dias úteis com menos de 30% da mediana de aberturas.

3. Horário do expediente:

- Pico de atualizações dos atendentes entre 8h e 18h
- Atualizações “Closed” ignoradas (fechamento automático, não indica trabalho humano)
- Tempo medido em **minutos úteis** (dias úteis, 8h às 18h)

Limpeza de dados

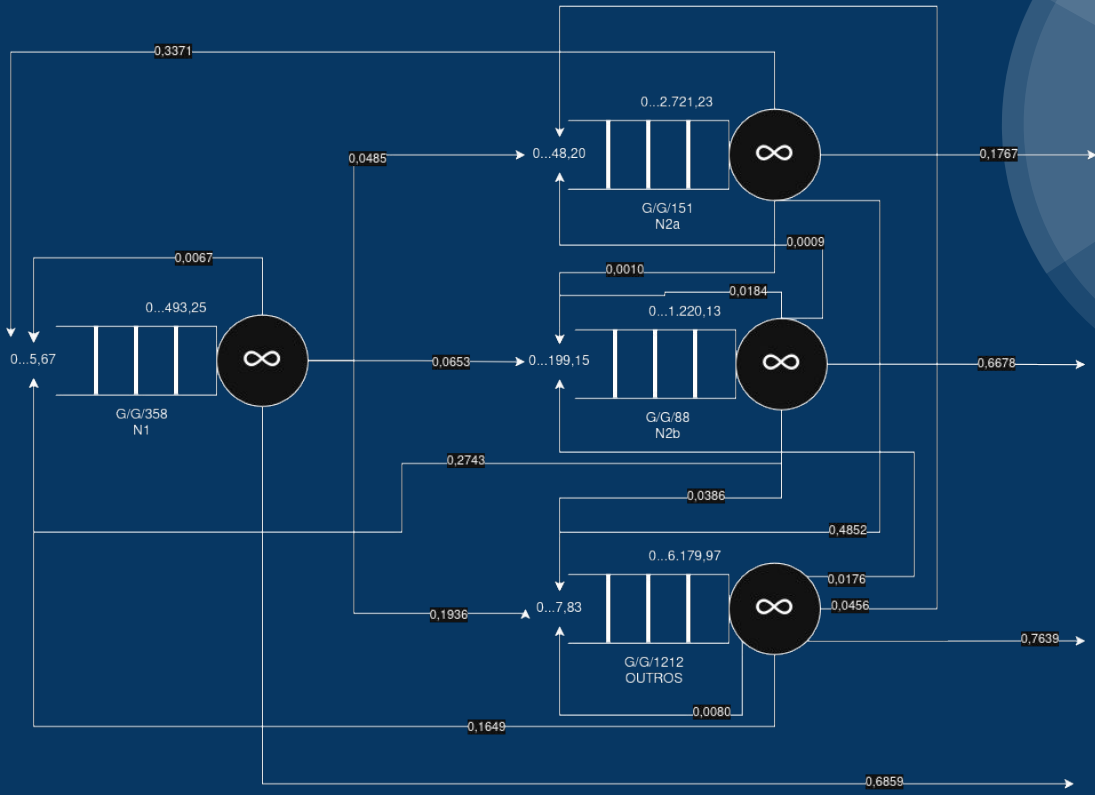
4. Definição das filas:

- Cada incidente foi quebrado em “visitas” a quatro filas (N1, N2a, N2b e OUTROS)
  “OUTROS” engloba os grupos com menor volume e quase não devolvem chamadas ao N1.

5. Parâmetros extraídos por fila

- **Chegadas:** intervalo médio entre chegadas externas
- **Atendimento:** tempo médio de permanência na fila
- **Servidores:** máximo de incidentes simultâneos na fila
- **Roteamento:** probabilidade de ir para cada fila ou sair do sistema
- Chegada e atendimento modelados como distribuição uniforme [0, 2×média]

Modelo (desenho):



Modelo (desenho):

4 filas, com chegadas do exterior em todas.
Tempo em minutos úteis.

Fila	Grupo real	Kendall	Chegada externa (min)	Atendimento (min)	mu por servidor	Servidores	Capacidade
N1	Group 70 (1 nível)	G/G/358	U[0; 5,67]	U[0; 493,25]	0,2433 por hora	358	Infinita
N2a	Group 20	G/G/151	U[0; 48,20]	U[0; 2.721,23]	0,0441 por hora	151	Infinita
N2b	Group 39	G/G/88	U[0; 199,15]	U[0; 1.220,13]	0,0984 por hora	88	Infinita
OUTROS	75 grupos agregados	G/G/1212	U[0; 7,83]	U[0; 6.179,97]	0,0194 por hora	1.212	Infinita

Probabilidades de Roteamento

De\Para	N1	N2a	N2b	OUTROS	Saída (resolvido)
N1	0,0067	0,0485	0,0653	0,1936	0,6859
N2a	0,3371	-	0,0010	0,4852	0,1767
N2b	0,2743	0,0009	0,0184	0,0386	0,6678
OUTROS	0,1649	0,0456	0,0176	0,0080	0,7639

(linha = fila de origem; as setas do desenho):

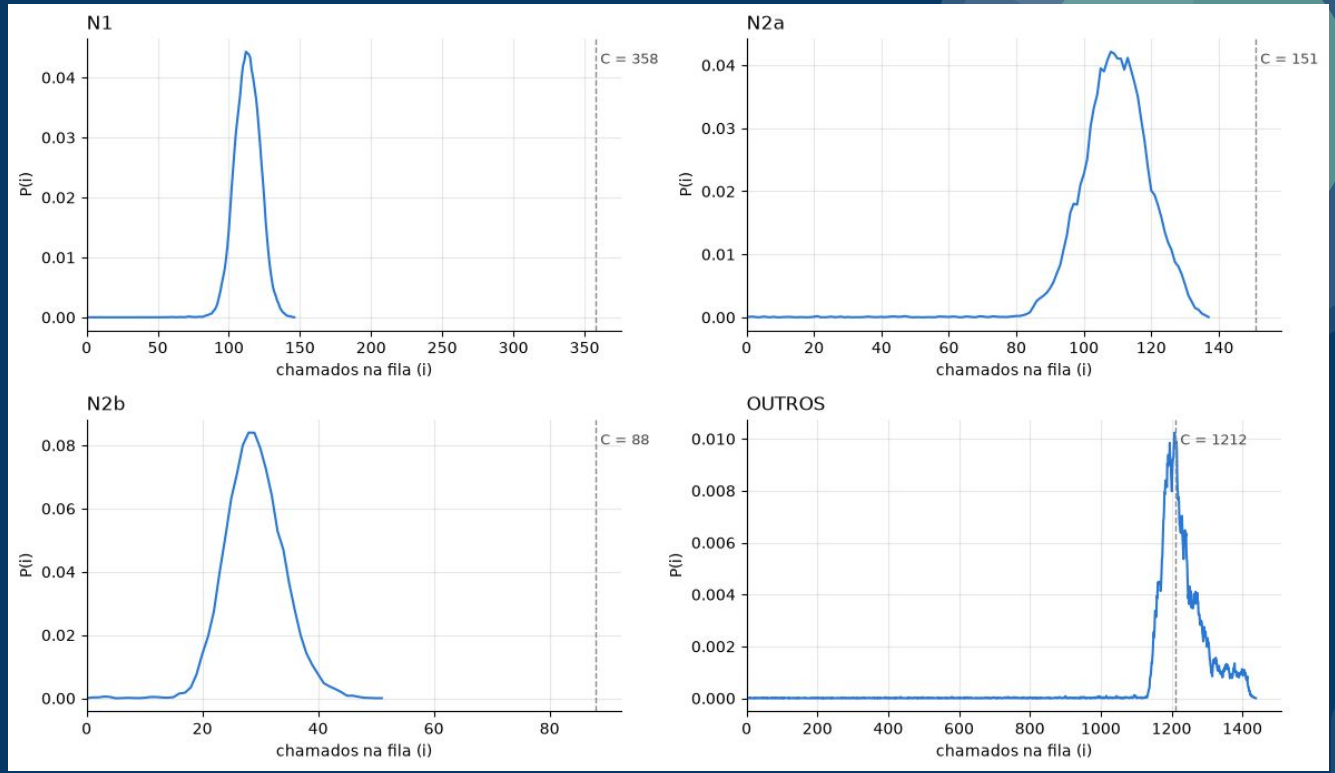
Resultados da Simulação - Métricas

N = População | D = Vazão por hora | U = Utilização
W = Tempo de Resposta (min) | P = Probabilidade de todos os servidores estarem ocupados

Fila	N	D	U	W	P	Perdas
N1	113,0	27,50	0,316	246,6	0,00	**0**
N2a	109,4	4,82	0,724	1.360,6	0,00	**0**
N2b	29,1	2,86	0,330	610,1	0,00	**0**
OUTROS	1.225,6	23,16	0,984	3.175,0	0,55	**0**

Configuração: semente 42 e 1.000.000 de aleatórios,
equivalentes a cerca de 640 dias úteis simulados.

Resultados da Simulação - Probabilidade dos estados



Resultados da Simulação

VS: Vazão simulada (por hora) | VO: Visitas observadas (por hora)
W: tempo de resposta simulado | PMO: Permanência média observada em minutos

Fila	VS	VO	W	PMO
N1	27,50	27,68	246,6	246,6
N2a	4,82	4,94	1.360,6	1.360,6
N2b	2,86	2,93	610,1	610,1
OUTROS	23,16	23,44	3.175,0	3.090,0

VS ≈ VO - A vazão simulada fica a menos de 2,5% da observada, então as chegadas e o roteamento reproduzem o fluxo real.

Gargalos e melhorias candidatas

Gargalo principal: "OUTROS" Utilização de 0,984, todos os servidores ocupados em 55% do tempo e espera média de 85 minutos úteis, a única fila com espera. Ela recebe chamados de todas as outras: 19,4% do que sai do N1 e 48,5% do que sai do N2a.

Segundo ponto de atenção: "N2a" Utilização de 0,724, e só 17,7% dos seus chamados são resolvidos ali: o resto volta ao N1 (33,7%) ou segue para OUTROS (48,5%).

N1 e N2b estão folgados (utilização de cerca de 0,32 a 0,33)

Melhorias candidatas:

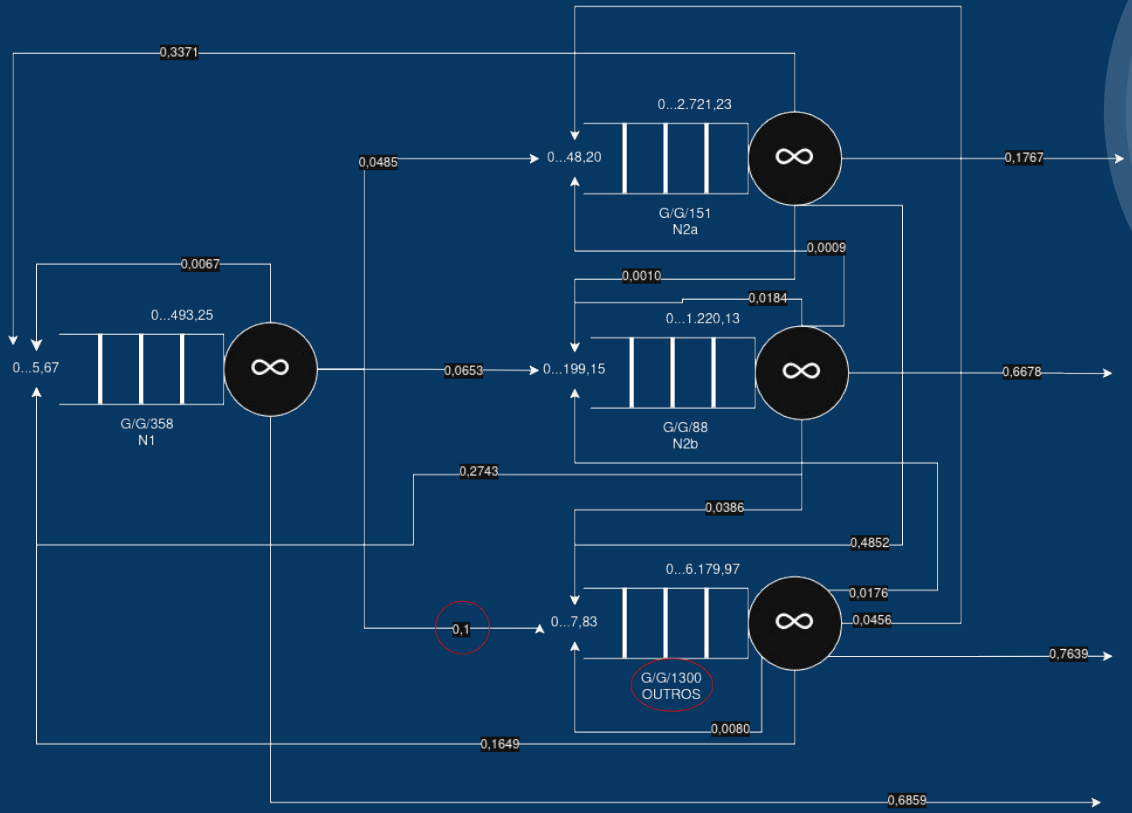
1. **Triagem melhor no N1 (N1.routing.OUTROS: 0.1936 -> 0,10):**

Para transferir a resolução de parte dos chamados que passam pra OUTROS, para serem resolvidos no próprio N1. A diferença vai pra saída.

2. **Mais capacidade no gargalo (OUTROS.servers: 1212 -> 1300, +7%)**

Assim todos chamados em outros poderiam ser atendidos em paralelo, não sendo necessária uma espera adicional para liberação de espaço na fila.

Desenho com as melhorias



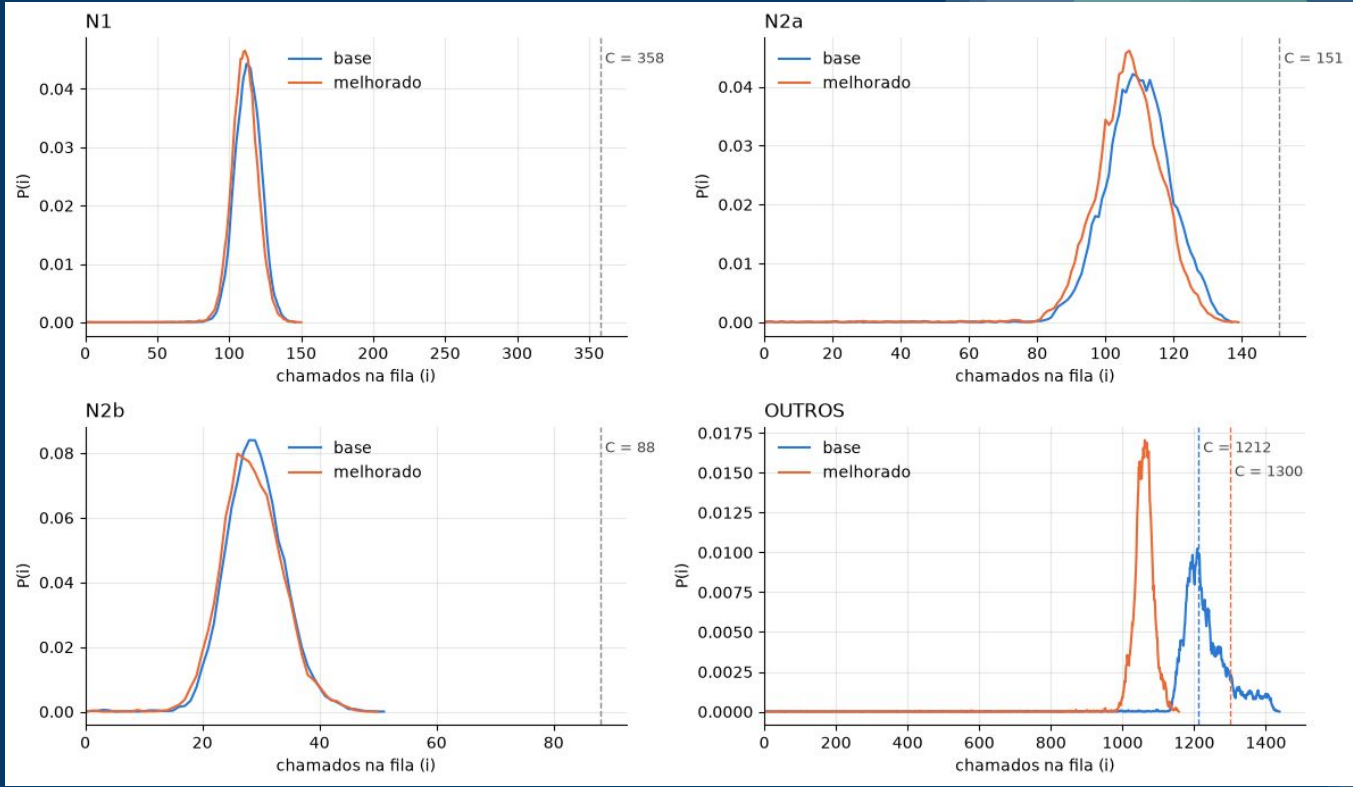
Resultados das Melhorias

- Espera cai de 85min para 0 e os servidores nunca ficam todos ocupados
- N1, N2a e N2b recebem um pouco menos de chamados
- Vazão cai em todas as filas pois os chamados circulam menos entre elas

Fila	N	D	U	W	P
N1	113,0 -> 110,9	27,50 -> 26,97	0,316 -> 0,310	246,6 -> 246,6	0,00 -> 0,00
N2a	109,4 -> 106,6	4,82 -> 4,70	0,724 -> 0,704	1.360,6 -> 1.360,6	0,00 -> 0,00
N2b	29,1 -> 28,6	2,86 -> 2,81	0,330 -> 0,325	610,1 -> 610,1	0,00 -> 0,00
OUTROS	1.225,6 -> 1.054,1	23,16 -> 20,47	0,984 -> 0,811	3.175,0 -> 3.090,0	0,55 -> 0,00

N = População | D = Vazão por hora | U = Utilização
W = Tempo de Resposta (min) | P = Probabilidade de todos os servidores estarem ocupados

Probabilidade dos estados

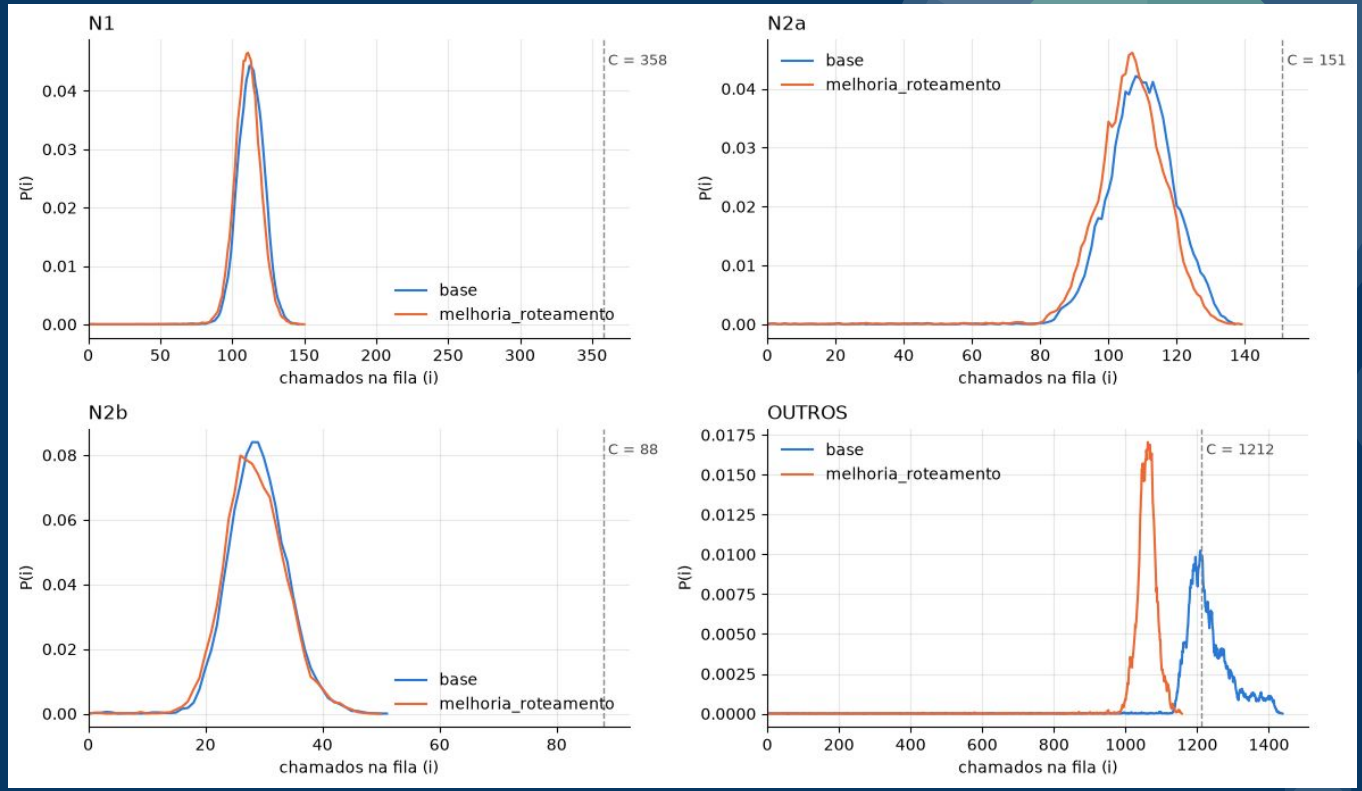


Qual melhoria foi a melhor?

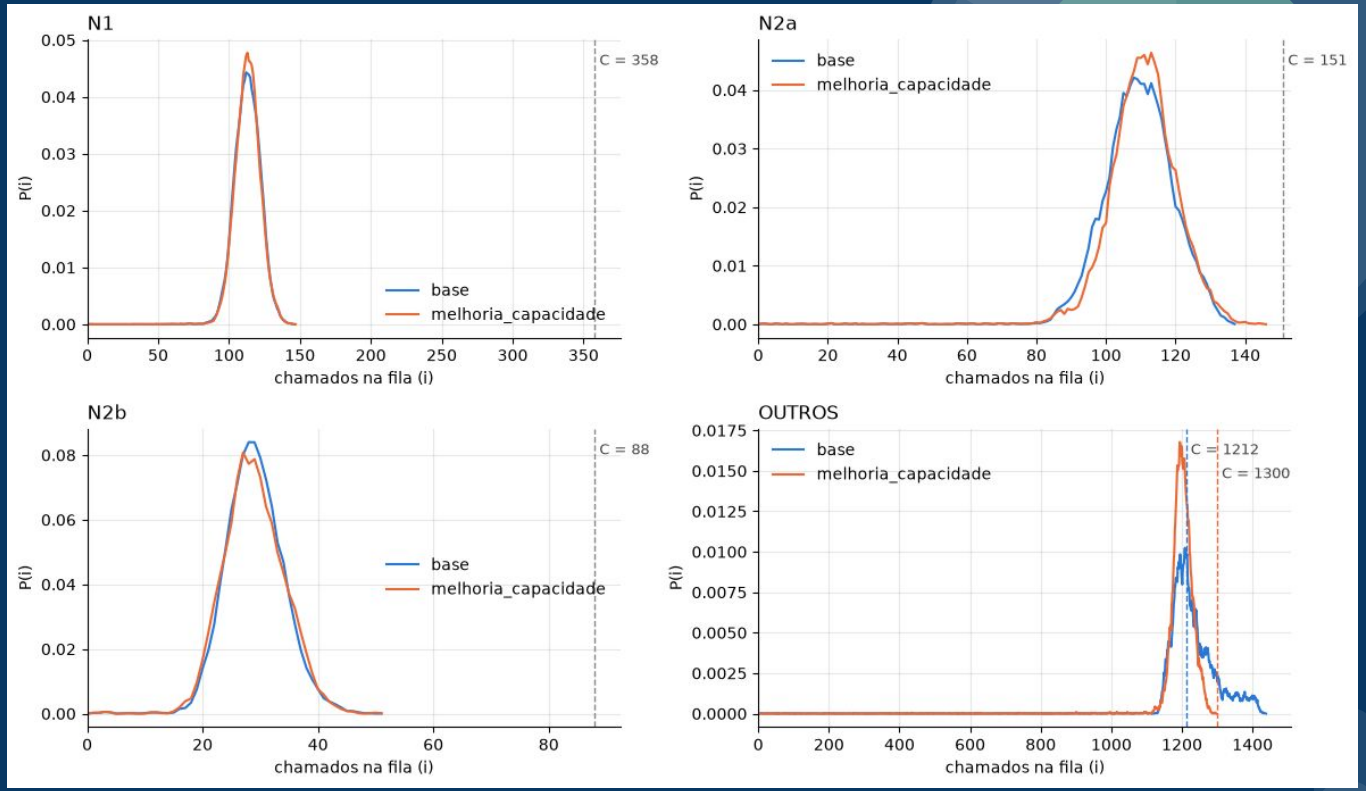
- Tempo por chamado: população total / chegadas externas
- A triagem resolve a causa, e no mesmo pico sobram 55 dos 1.212 servidores.
- A capacidade resolve por pouco, qualquer aumento de demanda volta a formar fila.
- Juntas, dão o mesmo resultado que apenas a triagem (os novos servers ficam ociosos)

Fila	Espera em OUTROS	Máx em OUTROS / C	Tempo por chamado na rede
Base	85 min	1.438/1.212	2.239
Só Triagem	0	1.157/1.212	1.971 min (-12%)
Só capacidade	0	1.297/1.300	2.196 min (-2%)
As duas	0	1.157/1.300	1.971 min

Probabilidade dos estados - Roteamento



Probabilidade dos estados - Capacidade



Conclusões

- OUTROS era o único gargalo, a única fila com espera
- Melhorar a triagem no N1 elimina o gargalo e reduz em 12% o tempo de um chamado na rede.
- Aumentar os servidores de OUTROS só compensa sem a triagem, e mesmo assim tem ganho de apenas 2%

Como vimos no M9: Vale a pena contratar mais, se o ganho é tão pequeno?

Limitações da simulação e da otimização

- O valor novo do roteamento de 0,10 é uma estimativa (os dados indicam algo entre 0,13 e 0,17)
- Supomos que N1 conseguiria resolver esses chamados sem demorar mais
- OUTROS agrega 75 grupos diferentes

Muito obrigado